Trabalho 3 (T3): Divisão e conquista com MPI

Ordenação de um vetor (Bubble Sort nas folhas) — Unidade 04

Integrantes: Bernardo Fioreze *(preencher demais integrantes)* | **Repositório:** https://github.com/BernardoFioreze/t3-mpi-divisao-conquista

Ambiente: cluster Atlântica (LAD), **2 nós exclusivos**; cada nó = 2× Intel Xeon E5520 @ 2,27 GHz = **8 núcleos físicos / 16 threads (HT) por nó** (`lscpu`), logo **16 núcleos físicos / 32 threads** nos 2 nós. $N = 200000$, 10 repetições por configuração (mediana / mín / máx), todas com `verificacao=OK`.

Análise dos resultados

1. Modelagem. Todos os processos rodam o mesmo executável (SPMD) e descobrem seu papel pelo `rank`. Na *versão original* a árvore é indexada como um heap: a raiz é o `rank` 0, um processo r tem filhos $2r{+}1$ e $2r{+}2$ e pai $(r{-}1)/2$ (`original.c`:9–10). O processo não conhece o tamanho do pedaço de antemão: ele o descobre com `MPI_Probe`/`MPI_Get_count` antes de alocar (`original.c`:99–102). Se o pedaço é $\leq \delta$ ele conquista com Bubble Sort (linhas 123–124); senão envia **as duas metades** aos filhos (linhas 129–130) **antes** de qualquer `MPI_Recv` (linhas 132–133), para os dois filhos trabalharem ao mesmo tempo, e intercala na volta (linha 134). Na *versão balanceada* o processo não entrega as duas metades: manda a metade direita ao ajudante $r + 2^{\text{nível}}$ (`MPI_Isend`, `balanceado.c`:90) e **fica com a esquerda**, descendo um nível (linha 95); recebe a direita ordenada de volta e intercala (linhas 98–100). Um não-raiz descobre onde nasceu pelo bit menos significativo do `rank`: nível inicial = $\texttt{ctz}(r) - 1$ (linha 170) e pai = $r \,\&\, (r{-}1)$ (linha 139). O `MPI_Isend` seguido de `MPI_Request_free` (linhas 90–92) evita bloquear e descarta a *request* porque o `MPI_Recv` do mesmo ajudante (linha 98) só retorna depois que a mensagem foi consumida. Com P potência de 2 todas as folhas têm N/P; com $P = 2^k - 1$ (caso da original) elas diferem em um elemento.

2. Speed-up, eficiência e a separação do ganho de algoritmo. A Tabela 1 mostra o ganho de algoritmo T_1/T_1^{δ} indo de 2,0× (δ=10^5) a 535× (δ=391): quase todo o "speed-up" acima de P vem daí, não do paralelismo. Por exemplo, na original com P=31 e δ=12500 temos $S = 125\times$ mas $S^{\delta} = 7{,}4\times$; e 7,4 × 16,9 (o ganho de algoritmo em δ=12500) ≈ 125. A S^{δ} é o paralelismo honesto (contra a *mesma* árvore em um processo) e a eficiência $E = S^{\delta}/P$ cai de 0,67 (P=3) a 0,24 (P=31) por causa da comunicação e da árvore (só as folhas calculam — ponto 3). Para a versão balanceada com **31 processos** (não potência de 2), as folhas têm tamanhos diferentes e um δ único não reproduz a árvore; por isso ela fica fora da Tabela 2 (que traz só as potências de 2, com S^{δ} e E), mas seu S é válido e medido: $T_P = 0{,}205$ s, $S = 197\times$, contra 125× da original no *mesmo* P=31 (ponto 5).

3. Balanceamento da carga nos níveis (original). Cada nó interno divide e então fica **parado** em `MPI_Recv` (`original.c`:132–133) até os filhos voltarem; apenas o nível das folhas executa Bubble Sort. Num dado instante os níveis superiores estão ociosos e, na volta, fazem só a intercalação barata ($O(n)$). É esse desbalanceamento que a versão balanceada ataca ao fazer o pai também ordenar uma folha.

4. Ganho com HT. Comparando P=15 (um processo por núcleo físico; há 16 físicos nos 2 nós) com P=31 (passa a usar as threads de Hyper-Threading): o tempo cai de 0,709 para 0,322 s (2,2×), mas o δ também muda (25000→12500). Olhando a S^{δ}, que isola o paralelismo, o ganho é só 6,93→7,41 (+7%). Ou seja, o HT quase não aumenta o paralelismo real: as duas threads de um núcleo dividem as mesmas unidades de execução e o Bubble Sort é limitado por CPU; o grosso da melhora de P=15 para 31 vem das folhas menores (algoritmo), não de mais processamento simultâneo.

5. Ganho com o balanceamento. Duas formas, como pede o enunciado. *Sem alterar o código* (mais processos que núcleos — série de oversubscription, Tabela 3): quem balanceia é o escalonador do SO (ponto 6). *Alterando o código* (versão balanceada): no mesmo P=31 o tempo cai de 0,322 para 0,205 s (1,57× mais rápido) porque os processos internos deixam de ficar ociosos e também ordenam uma folha. Em potências de 2 a eficiência da balanceada se mantém alta ($E \approx 0{,}49$ até P=8) enquanto a da original já está caindo.

6. Desempenho de 63 a 1023 processos: espera ativa × núcleo cedido. Com mais processos que as 32 threads de hardware, a **espera ativa** (`OMPI_MCA_mpi_yield_when_idle=0`) faz um processo bloqueado em `MPI_Recv` ocupar o núcleo em laço; com `OMPI_MCA_mpi_yield_when_idle=1` ele **cede o núcleo**. As duas séries foram medidas com a variável **definida explicitamente** (0 e 1), como pede a errata do enunciado, pois deixá-la indefinida pode já ceder o núcleo e fazer as duas medirem a mesma coisa (foi o que observamos: com a variável indefinida a espera ativa era bem mais rápida, sinal de que o núcleo já estava sendo cedido). Em oversubscription moderado o *yield* ganha claramente: em P=127, 0,519 s (espera ativa) contra 0,184 s (cede o núcleo), 2,8×; em P=63, 0,333 contra 0,214. A diferença entre as duas séries é exatamente quanto o escalonador do SO consegue balancear quando os processos cooperam cedendo o núcleo que não estão usando. A partir de P=255 os dois pioram (muito além de 32 threads: troca de contexto e pressão de memória dominam) e a eficiência $E = S^{\delta}/32$ fica ínfima, mas o *yield* degrada menos. O caso P=1023 rodou completo nos dois modos após elevar `ulimit -n` a 512000 e usar `opal_set_max_sys_limits` (senão estourava o limite de *pipes* do SO ao encaminhar a saída de cada rank).

7. Uso de ferramentas de IA. Declaramos o uso do Claude (Anthropic) para: entender o enunciado; derivar a implementação a partir do pseudocódigo (indexação em heap na original; esquema de "pente"/Radenski na balanceada); escrever os scripts `sbatch` e o `analise.py`; e depurar erros do cluster (falha do PMIx e o limite de *pipes* em P=1023). Revisamos o código linha a linha, sabemos explicar cada chamada MPI, e as decisões de modelagem e de medição são do grupo.

Tabela 1: Referências sequenciais (N=200000, 1 processo). A coluna *níveis* é o número de níveis da árvore (nível 1 = vetor inteiro, sem divisão, $\delta = N$ — é o próprio T_1); cada nível a mais divide as folhas pela metade. Todas rodam em um só processo. A mesma árvore de nível n corresponde a $P = 2^n - 1$ processos na versão original e $P = 2^{n-1}$ na balanceada (daí os δ compartilhados na Tabela 2). O ganho de algoritmo T_1/T_1^δ explica por que S passa de P.

nível	δ	mediana (s)	mín (s)	máx (s)	T_1/T_1^δ
1 (T_1)	200000	40,354	40,339	40,383	1,00
2	100000	20,051	20,033	20,073	2,01
3	50000	9,961	9,913	9,975	4,05
4	25000	4,912	4,904	4,921	8,22
5	12500	2,384	2,379	2,387	16,93
6	6250	1,125	1,113	1,134	35,87
7	3125	0,552	0,547	0,562	73,14
8	1563	0,290	0,287	0,292	139,35
9	782	0,152	0,149	0,155	265,23
10	391	0,075	0,075	0,081	535,04

Tabela 2: Original ($P = 2^n - 1$) e balanceada ($P = 2^{n-1}$) lado a lado, por nível n da árvore. No mesmo nível as duas ordenam folhas do **mesmo tamanho** ($\delta = N/2^{n-1}$, coluna única); o que muda é quantos processos cada uma usa para chegar lá. $S = T_1/T_P$; $S^\delta = T_1^\delta/T_P$; $E = S^\delta/P$; tempos em segundos. O nível 1 (original com P=1, vetor inteiro) coincide com T_1 da Tabela 1 (T_P=40,39, S=1,00); a balanceada começa no nível 2 e a original não alcança o nível 6.

		original					**balanceada**				
nível	δ	P	T_P	S	S^δ	E	P	T_P	S	S^δ	E
2	100000	3	10,053	4,01	1,99	0,665	2	20,081	2,01	1,00	0,499
3	50000	7	2,577	15,66	3,87	0,552	4	4,992	8,08	1,99	0,499
4	25000	15	0,709	56,90	6,93	0,462	8	1,262	31,98	3,90	0,487
5	12500	31	0,322	125,38	7,41	0,239	16	0,361	111,84	6,61	0,413
6	6250	— (original vai só até P=31) —					32	0,170	236,72	6,56	0,205

Tabela 3: Oversubscription da versão original (63–1023 processos nos mesmos 2 nós = 32 threads). Duas execuções, com a variável definida explicitamente: espera ativa (`OMPI_MCA_mpi_yield_when_idle=0`) e cede o núcleo (`=1`). $E = S^\delta/32$ (eficiência relativa às 32 threads de hardware).

	espera ativa (`yield_when_idle=0`)					cede o núcleo (`=1`)			
P	δ	T_P (s)	S	S^δ	E	T_P (s)	S	S^δ	E
63	6250	0,333	121,2	3,38	0,106	0,214	188,3	5,25	0,164
127	3125	0,519	77,7	1,06	0,033	0,184	219,8	3,01	0,094
255	1563	0,728	55,4	0,40	0,012	0,228	177,2	1,27	0,040
511	782	1,906	21,2	0,08	0,002	0,427	94,5	0,36	0,011
1023	391	6,534	6,2	0,01	0,000	2,119	19,1	0,04	0,001

Teste extra: $N = 1.000.000$

Para ver o comportamento em escala maior, repetimos o experimento com N=10^6 (3 repetições, tudo num único job). O foco foi a oversubscription profunda, então o sequencial rodou só os níveis 10–13 (sem T_1); por isso original e balanceado aparecem só com o **tempo bruto** T_P (sem S/S^δ). A Tabela 4 compara as duas versões por nível (mesmo δ = mesmas folhas). Dois resultados se confirmam em escala: (i) no *mesmo* δ o balanceado é $\approx 2\times$ mais lento que o original (ex. nível 2: 474 vs 237 s), pela serialização do topo (o pai calcula antes de o `MPI_Isend` grande progredir, então o ajudante espera); mas no *mesmo* P ele ganha, por alcançar uma árvore mais profunda. (ii) A oversubscription tem **teto** aqui: em 2 nós, só P=1023 rodou; P=2047 e 4095 estouraram o *timeout* de 20 min na espera ativa e P=8191 falhou no `MPI_Init` (o runtime não lança 8191 processos). No P=1023 o *yield* foi **3,1**× mais rápido que a espera ativa (2,25 vs 7,08 s).

Tabela 4: N=10^6, 3 repetições, tempo bruto T_P (sem T_1, logo sem S/S^δ para as versões paralelas). À direita, a única série de oversub que completou (P=1023), com $E = S^\delta/32$.

original × balanceado (tempo T_P, s)						**oversub P=1023**			
nível	δ	orig P	T_P	bal P	T_P	modo	T_P	S^δ	E
2	500000	3	237,2	2	474,2	espera ativa (=0)	7,08	0,25	0,008
3	250000	7	60,0	4	118,7	cede núcleo (=1)	2,25	0,77	0,024
4	125000	15	15,8	8	30,4	$P \geq 2047$: *timeout*/falha no lançamento			
5	62500	31	6,26	16	8,20				
6	31250	—	—	32	3,13				

O código completo (`src/sequencial.c`, `src/original.c`, `src/balanceado.c`), os scripts `sbatch` e as saídas brutas do Slurm estão no repositório público citado no cabeçalho; as referências de linha acima apontam para esses arquivos.